

Uso de una U-Net convolucional para separación binaria de imágenes de una gota de agua en levitación acústica.

Proyecto Final

Zepeda Montiel Natalia Margarita, NUA: 462571

Introducción

En el Laboratorio de Biofotoacústica de la Universidad de Guanajuato se realiza investigación en cavidades ópticas resonantes de polímeros y líquidos dopados con colorantes orgánicos como medio activo. Se puede levitar objetos pequeños usando ultrasonido si las frecuencias se acoplan para generar nodos de presión en regiones específicas de un ensamble de levitador acústico, dichas regiones de presión dependen de las frecuencias y de la geometría del sistema experimental. El agua puede servir como objeto de levitación ya que se puede dosificar en gotas pequeñas (microlitros), pero esta a su vez se evapora con el tiempo, por lo tanto, su volumen disminuye en el tiempo.

Objetivo

Hacer un dataset con un conjunto de imágenes experimentales de una gota de agua levitando acústicamente, hacer sus máscaras y posteriormente entrenar un modelo de redes neuronales convolucionales con una arquitectura U-Net para tener imágenes de salida con bordes más definidos por segmentación binaria y facilitar su detección, en específico para los volúmenes más pequeños.

Justificación

En la óptica y física de láseres es fundamental tener cavidades ópticas que tengan la mayor eficiencia cuántica posible, y esto va a depender enteramente de la geometría y materiales de estas.

Las gotas de agua son un gran candidato para una buena cavidad óptica ya que tiene paredes uniformes debido a la tensión superficial presente por los puentes de Hidrógeno y es posible añadir un colorante que tenga la capacidad de dopar el material de la cavidad para su emisión láser o fluorescencia. Con un levitador acústico se pueden crear geometrías elipsoidales de líquidos levitando. Con los recursos disponibles muchas veces no es posible tener instrumentos como cámaras de alta resolución por lo que es factible hacer un procesamiento extra en los datos experimentales, y las gotas de agua levitadas no son la excepción. Cuando la gota de agua está por evaporarse se vuelve inestable y con métodos de procesamiento de imágenes, como un método Canny, suele dificultarse el seguimiento y detección de bordes, a esto sumándole que la gota de agua es transparente. Por ello, en este proyecto final se desarrolla un modelo de aprendizaje para que la imagen se seccione de manera que los bordes sean más distinguibles entre el fondo y la gota para que resulten mediciones más precisas.

Marco Teórico

La levitación acústica es un fenómeno que se basa en el uso de ondas sonoras a muy alta frecuencia (más de 20,000 Hz), es decir en el rango del ultrasonido. Este fenómeno contrarresta la fuerza de gravedad creando regiones de presión del medio elástico, en este caso el aire donde se pueden quedar suspendidas en equilibrio a modo de atrapamiento.

Para lograr dicho atrapamiento se utilizan componentes electrónicos como transductores electrónicos como altavoces ultrasónicos, drivers y un microcontrolador Arduino programable [1].




Figura 1: Imagen de simulación de presencia de los nodos de presión generados por interferencia de ondas sonoras ultrasónicas en un levitador acústico [1].

Teniendo ahora un ensamble experimental para la levitación acústica de microgotas se puede aprovechar dopándolas con colorantes como lo es la Rodamina B y levantarlas para un aislamiento de una cavidad óptica resonante la cual se pueda caracterizar tomando en cuenta que la gota de agua se evapora por la presión de vapor, por lo que su volumen disminuye en el tiempo y se necesite un tracking de su volumen para analizarlo.

Una cavidad óptica resonante es un sistema que permite la resonancia de ondas electromagnéticas de luz. Dicha resonancia en el sistema se da por la reflexión total interna en el sistema lo que provoca una excitación de las moléculas de agua en conjunto con el dopante que en conjunto son el medio activo y que libere su energía por emisión estimulada lo que se puede medir posteriormente como luz en un espectroscopio, deseablemente con su espectro con picos en una longitud de onda bien definida a lo cual se le llama láser.




Figura2: Ensamble experimental del levitador acústico en el Laboratorio de Biofotoacústica en la División de Ciencias e Ingenierías de la Universidad de Guanajuato.




Figura 3: Foto tomada desde la cámara superior.



Figura 4: Foto tomada desde la cámara frontal.

Las redes neuronales convolucionales (CNN), están clasificadas dentro de la inteligencia artificial en el área del aprendizaje profundo (Deep Learning). Una arquitectura de red neuronal convolucional pensada para la segmentación de imágenes médicas que cobró gran relevancia fue la U-Net, llamada así por su arquitectura o diagrama en forma de U.




Figura 5: Diagrama de arquitectura U-Net [3].

En la Figura 5 se muestra el diagrama de arquitectura de una red neuronal convolucional con arquitectura U-Net del artículo original. Observamos que es un esquema bien detallado de todos los pasos que se llevan a cabo, en general consta de una primer parte de procesamiento por convoluciones, en la figura se especifican el número de filtros aplicados, después de cada convolución se hace un maxpooling de 2x2, es decir reduce la imagen a la mitad en cada convolución, también se concatena las convoluciones con las deconvoluciones(subida) aumentando de nuevo la dimensionalidad de la imagen al doble y finaliza con una convolución de 1x1, dando como

La implementación de esta arquitectura ha resultado muy eficaz en tareas como la identificación de órganos, células, fotografías aéreas y su segmentación, así que para la identificación de bordes de una gota levitando no debe ser una tarea difícil por lo que fue la elegida para este proyecto.

Parámetros e hiperparámetros en el modelo U-Net utilizado:

1. Tamaño y modo de imagen de entrada:
 - Imagen: 128x128, RGB.
 - Máscara: 128x128, L.
2. Tamaño de dataset de entrenamiento: 150.

3. Tamaño de lote por iteración (batch size): 20.
4. Épocas (epochs):20.
5. Drop out: 0.1 (10%).
6. Función de activación: ReLu para todas las capas ocultas y Sigmoid para la última convolución de 1x1.
7. Optimizador: Adam (Descenso de Gradiente Estocástico).
8. Función de pérdida: binary_crossentropy (para clasificación binaria) →0.0140 .
9. Métrica de rendimiento: Accuracy → 0.9448.

Los parámetros e hiperparámetros se eligieron así principalmente para no tener demasiado gasto de cómputo, se tiene un dataset de entrenamiento no tan extenso, pero las segmentaciones no son figuras muy complejas, por lo que el tamaño se considera arbitrariamente razonable. Es muy importante considerar todos estos parámetros en especial con librerías de TensorFlow donde las dimensiones y modos de los datos de entrada son fundamentales para que el código funcione y haga las operaciones correctamente.

El dataset se cargó una memoria en la nube para leerse desde Google Colaboratory, esto para hacer uso de la GPU y tener un menor costo computacional en cuanto a tiempo.

Diagrama de bloques

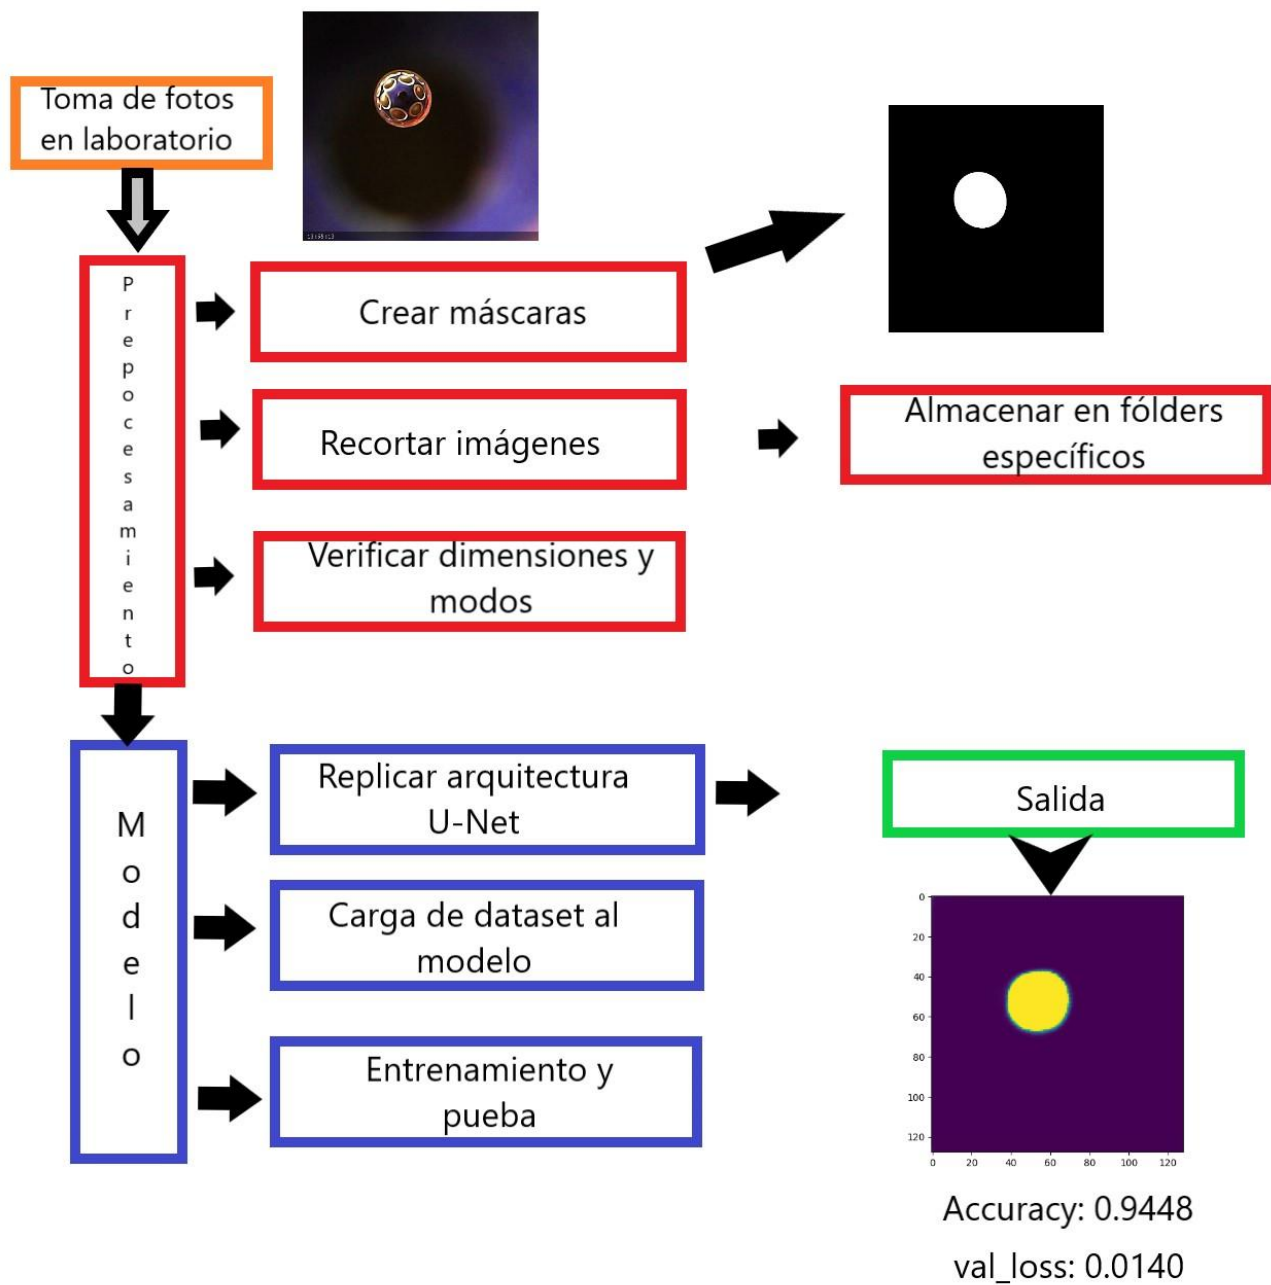


Figura 6: diagrama de bloques.

Actividades de programación

Las tareas realizadas fueron:

1. Obtención del dataset experimental en el laboratorio de gotas levitando acústicamente.
2. Elaboración de 150 máscaras a mano en el software de dibujo Paint3D de Windows.
3. Elaboración de códigos de una estructura de dataset legible para TensorFlow lo cual implica redimensionalidad a imagen cuadrada, modo de la imagen RGB para la imagen y modo L para la máscara (Luminance).
4. Replicamiento de la arquitectura de Red Neuronal Convolutiva U-Net como lo está en el artículo original usando las bibliotecas de TensorFlow.
5. Entrenamiento de un modelo de aprendizaje para segmentación y resalte de borde para su posterior análisis.
6. Pruebas con el modelo.

En conclusión, se logró obtener un modelo de Aprendizaje de Máquina utilizando una arquitectura U-Net con ayuda de la librería de TensorFlow donde se le da de entrada una fotografía de una gota en levitación acústica y da una imagen de salida con bordes más definidos debido que se usó una clasificación binaria, es decir el fondo y la gota de agua. Posteriormente aplicar un método de detección de bordes clásico de procesamiento de imágenes como el método Canny y ajustar un círculo o elipse según sea el caso para tener una medición más precisa del volumen de la gota levitando y no perder datos, más particularmente cuando el tamaño de la gota de agua levitando ya es muy reducido. Se obtuvo un accuracy muy alto a pesar del uso de un dropout de 10%, pero esto se debe a que las imágenes de entradas son todas muy parecidas al igual que sus máscaras variando principalmente en escala y muy poco en geometría.

Referencias

- [1] Marzo, A., Barnes, A & Drrinwater, B. “TinyLev: A multi-emitter single-axis acoustic levitator”, AIP (2017) Volume 88, Issue 8, <https://doi.org/10.1063/1.4989995>
- [2] Reynoso, H., et al. “Low-cost fabrication of microlasers based on polymeric pedestals”, Applied Optics (2021) Vo 60, Issue 8, <https://doi.org/10.1364/AO.410615>
- [3] Ronneberger, O., Fischer, P., & Brox, T., “U-Net: Convolutional Networks for Biomedical Image Segmentation”, University of Freiburg, Germany (2015), <https://arxiv.org/pdf/1505.04597.pdf>